



УНИВЕРЗИТЕТ У НОВОМ САДУ
ФАКУЛТЕТ ТЕХНИЧКИХ
НАУКА У НОВОМ САДУ



Ненад Берић

Класификација типа стреса из биосигнала са носивог сензора

ЗАВРШНИ РАД

Основне академске студије

Нови Сад, 2026

	УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА 21000 НОВИ САД, Трг Доситеја Обрадовића 6	
	КЉУЧНА ДОКУМЕНТАЦИЈСКА ИНФОРМАЦИЈА	

Редни број, РБР:		
Идентификациони број, ИБР:		
Тип документације, ТД:		Монографска документација
Тип записа, ТЗ:		Текстуални штампани материјал
Врста рада, ВР:		Дипломски - бечелор рад
Аутор, АУ:		Ненад Берић
Ментор, МН:		Др Игор Дејановић, редовни професор
Наслов рада, НР:		Класификација типа стреса из биосигнала са носивог сензора
Језик публикације, ЈП:		српски/хирилица
Језик извода, ЈИ:		српски/енглески
Земља публиковања, ЗП:		Република Србија
Уже географско подручје, УГП:		Војводина
Година, ГО:		2026
Издавач, ИЗ:		Ауторски репринт
Место и адреса, МА:		Нови Сад, трг Доситеја Обрадовића 6
Физички опис рада, ФО: (поглавља/страна/ цитата/табела/слика/графика/прилога)		5/43/25/3/7/0/2
Научна област, НО:		Електротехничко и рачунарско инжењерство
Научна дисциплина, НД:		Примењене рачунарске науке и информатика
Предметна одредница/Кључне речи, ПО:		Стрес, биосигнали, носиви сензори, машинско учење, класификација, електродермална активност, варијабилност срчане фреквенције
УДК		
Чува се, ЧУ:		У библиотеци Факултета техничких наука, Нови Сад
Важна напомена, ВН:		
Извод, ИЗ:		У раду се проблем детекције стреса из биосигнала носивог сензора формулише као класификација у једну од четири класе: стање мировања, физички стрес, когнитивни стрес и емоционални стрес. Коришћен је скуп података снимљен уређајем Empratica E4 код 20 испитаника. Обележја у временском и фреквенцијском домену рачунају се над прозорима сигнала, а селекција спроводи се пермутационом важношћу. Најбољи резултат, макро F1 меру 0,770, остварује Random Forest: физички стрес препознаје се најпоузданије, а емоционални најслабије, услед хабитуације. Температура коже уноси ефекат забуне услед фиксног редоследа фаза протокола.
Датум прихватања теме, ДП:		
Датум одбране, ДО:		01.01.2025
Чланови комисије, КО:	Председник:	Др Петар Петровић, ванредни професор
	Члан:	Др Марко Марковић, доцент
	Члан:	
	Члан, ментор:	Др Игор Дејановић, редовни професор
		Потпис ментора

	UNIVERSITY OF NOVI SAD • FACULTY OF TECHNICAL SCIENCES 21000 NOVI SAD, Trg Dositeja Obradovića 6	
	KEY WORDS DOCUMENTATION	
Accession number, ANO :		
Identification number, INO :		
Document type, DT :	Monographic publication	
Type of record, TR :	Textual printed material	
Contents code, CC :		
Author, AU :	Nenad Berić	
Mentor, MN :	Igor Dejanović, Phd., full professor	
Title, TI :	Stress Type Classification from Wearable Sensor Biosignals	
Language of text, LT :	Serbian	
Language of abstract, LA :	Serbian/English	
Country of publication, CP :	Republic of Serbia	
Locality of publication, LP :	Vojvodina	
Publication year, PY :	2026	
Publisher, PB :	Author's reprint	
Publication place, PP :	Novi Sad, Dositeja Obradovica sq. 6	
Physical description, PD : (chapters/pages/ref./tables/pictures/graphs/appendixes)	5/43/25/3/7/0/2	
Scientific field, SF :	Electrical and Computer Engineering	
Scientific discipline, SD :	Applied computer science and informatics	
Subject/Key words, S/KW :	Stress, biosignals, wearable sensors, machine learning, classification, electrodermal activity, heart rate variability	
UC		
Holding data, HD :	The Library of Faculty of Technical Sciences, Novi Sad	
Note, N :		
Abstract, AB :	The thesis addresses stress type detection from wearable-sensor physiological signals, formulated as classification into one of four classes: relaxation, physical stress, cognitive stress, and emotional stress. The dataset used is recorded with an Empatica E4 wristband on 20 subjects during a controlled laboratory protocol. Time- and frequency-domain features are extracted from 60-second signal windows, with feature selection performed using permutation importance. Random Forest achieves the best result, a macro-averaged F1 score of 0.770, recognizing physical stress most reliably and emotional stress least reliably, due to habituation. Feature importance analysis reveals that skin temperature introduces a confounding effect caused by the fixed order of protocol phases.	
Accepted by the Scientific Board on, ASB :		
Defended on, DE :	01.01.2025	
Defended Board, DB :	President:	Petar Petrović, Phd., assoc. professor
	Member:	Marko Marković, Phd., asist. professor
	Member:	
	Member, Mentor:	Igor Dejanović, Phd., full professor
		Menthor's sign



УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА
21000 НОВИ САД, Трг Доситеја Обрадовића 6

ИЗЈАВА О НЕПОСТОЈАЊУ СУКОБА ИНТЕРЕСА

Изјављујем да нисам у сукобу интереса у односу ментор – кандидат и да нисам члан породице (супружник или ванбрачни партнер, родитељ или усвојитељ, дете или усвојеник), повезано лице (крвни сродник ментора/кандидата у правој линији, односно у побочној линији закључно са другим степеном сродства, као ни физичко лице које се према другим основама и околностима може оправдано сматрати интересно повезаним са ментором или кандидатом), односно да нисам зависан/на од ментора/кандидата, да не постоје околности које би могле да утичу на моју непристрасност, нити да стичем било какве користи или погодности за себе или друго лице било позитивним или негативним исходом, као и да немам приватни интерес који утиче, може да утиче или изгледа као да утиче на однос ментор-кандидат.

У Новом Саду, дана _____

Ментор

Кандидат

Садржај

1	Увод	1
2	Актуелно стање у области	3
2.1	Физиолошки сигнали коришћени у истраживањима стреса	3
2.2	Бихевиорални експерименти за индукцију стреса	4
2.3	Обрада биосигнала	4
2.4	Екстракција обележја из сигнала	5
2.5	Машинско учење за класификацију	5
2.6	Метрике евалуације модела	6
2.7	Преглед сродних истраживања	6
3	Методологија	9
3.1	Архитектура система	9
3.2	Опис скупа података	9
3.3	Предобрада сигнала	12
3.4	Екстракција обележја	14
3.5	Селекција обележја	15
3.6	Модел машинског учења	16
3.7	Валидација и подешавање хиперпараметара	17
3.8	Извоз резултата	17
4	Резултати	19
4.1	Перформансе модела	19
4.2	Детаљни резултати најбољег модела	20
4.3	Анализа важности обележја	21
4.4	Дискусија резултата	23
5	Закључак	27
5.1	Резиме	27
5.2	Ограничења система	27
5.3	Изазови и прилагођавања током рада	28
5.4	Даља потенцијална унапређења	29
	Списак слика	31
	Списак табела	33
	Списак коришћених скраћеница	35
	Списак коришћених појмова	37
	Биографија	39
	Литература	41

Глава 1

Увод

Континуирано праћење физиолошког стања путем носивих уређаја (енг. *wearable devices*) у последњој деценији постало је уобичајена пракса, како у контексту личне добробити тако и у превенцији прекомерног оптерећења на радном месту. Рано препознавање стреса омогућава благовремену интервенцију пре него што продужена, неидентификована изложеност доведе до постепеног опадања психофизичке добробити. За разлику од повремених лабораторијских мерења, носиви сензори омогућавају непрекидно и ненаметљиво прикупљање физиолошких сигнала током свакодневних активности, чиме отварају простор за аутоматску детекцију стреса ван контролисаних услова.

Већина постојећих система за детекцију стреса своди проблем на бинарну класификацију: присуство или одсуство стреса. Овакав приступ занемарује чињеницу да се физиолошки одговор организма разликује у зависности од узрока стреса: физички напор, когнитивно оптерећење и емоционална узнемиреност изазивају различите обрасце промена у сигнаlima попут покрета, електродермалне активности (енг. *electrodermal activity*, EDA) и срчане фреквенције. Познавање типа стреса представља предуслов за смислену и циљану интервенцију, на пример препоруку одмора код физичког напора наспрам кратке паузе код когнитивног оптерећења.

У раду се проблем формулише као класификација у једну од четири класе: Relax (стање мировања), Physical (физички стрес), Cognitive (когнитивни стрес) и Emotional (емоционални стрес), на основу 60-секундних прозора сигнала измерених носивим сензором на зглобу: убрзања, електродермалне активности, температуре коже, срчане фреквенције и засићености крви кисеоником (SpO₂, енгл. *blood oxygen saturation*). Подаци потичу из јавно доступног скупа података за процену неуролошког стања, снимљеног уређајем Empatica E4 код 20 здравих испитаника током контролисаног лабораторијског протокола [1].

Пут од сирових сигнала до коначне класификације обухвата обраду и нормализацију сигнала, екстракцију обележја у временском и фреквенцијском домену, те примену класичних алгоритама машинског учења за класификацију прозора у једну од четири класе.

Главни технички допринос рада представља фреквенцијска анализа сигнала, прилагођена карактеристикама сваког канала понаособ, док анализа важности обележја открива да температура коже уноси ефекат забуне услед фиксног редоследа

фаза протокола, чиме се доводи у питање њена стварна физиолошка информативност за препознавање стреса.

Рад је организован у пет поглавља. Поглавље 2 даје преглед актуелног стања у области: физиолошких сигнала, протокола за индукцију стреса, метода обраде сигнала и машинског учења коришћених у сродним истраживањима. Поглавље 3 описује методологију спроведену у раду: скуп података, обраду сигнала, екстракцију и селекцију обележја, коришћене моделе и поступак валидације. Поглавље 4 приказује добијене резултате и њихову дискусију у поређењу са сродним истраживањима. Поглавље 5 сумира закључке, ограничења рада и правце даљег унапређења.

Глава 2

Актуелно стање у области

2.1 Физиолошки сигнали коришћени у истраживањима стреса

Фотоплетизмографија (енг. *photoplethysmography*, PPG) представља оптичку методу мерења промена запремине крви у периферном васкуларном ткиву, засновану на детекцији количине светлости коју кожа рефлектује или пропушта при сваком откуцају срца. Због једноставности и ниске цене сензора, PPG представља основну технологију на којој почива мерење срчане фреквенције код већине носивих уређаја на зглобу [2]. Засићеност крви кисеоником (SpO₂) мери се пулсном оксиметријом, методом која упоређује апсорпцију светлости две таласне дужине од стране оксигенисаног и деоксигенисаног хемоглобина у крви; код здравих особа ова вредност је чврсто хомеостатски регулисана и у мировању остаје у уском опсегу, независно од краткотрајних спољашњих утицаја [3].

Електродермална активност (EDA) одражава промене електричне проводљивости коже узроковане активношћу знојних жлезда, које су, за разлику од већине других физиолошких система, под искључивом контролом симпатичког нервног система. Сигнал EDA уобичајено се раздваја на тоничку компоненту (енг. *tonic*), која представља спор базни ниво проводљивости коже, и фазну компоненту (енг. *phasic*), која обухвата брзе, краткотрајне одговоре изазване појединачним стимулусима [4]. Температура коже мења се услед периферне вазоконстрикције (сужевања крвних судова у кожи као дела аутономног одговора на стрес), при чему се крв преусмерава ка виталним органима, што доводи до опадања површинске температуре екстремитета [5]. Акцелерометрија (енг. *accelerometry*) омогућава мерење убрзања тела дуж више оса и уобичајено се користи за детекцију покрета и нивоа физичке активности носиоца уређаја [6].

Варијабилност срчане фреквенције (енг. *heart rate variability*, HRV) описује промену временског размака између узастопних откуцаја срца, познатог као RR интервал, и представља показатељ активности аутономног нервног система. Стандардне мере обухватају RMSSD (енг. *root mean square of successive differences*), корен средње квадратне вредности сукцесивних разлика RR интервала; SDNN (енг. *standard deviation of NN intervals*), стандардну девијацију трајања интервала; и однос LF/HF (енг. *low frequency/high frequency ratio*), однос снаге ниско- и високофреквентне компоненте спектра, који се тумачи као показатељ равнотеже симпатичке и парасимпатичке активности [7]. Пошто се ове мере рачунају из низа откуцај-по-откуцај интервала,

поуздано одређивање захтева сирови таласни облик сигнала из којег се детектује сваки појединачни откуцај; унапред усредњена вредност срчане фреквенције за то није довољна. Валидационе студије показују да носиви уређаји засновани на PPG сензору, попут Empatica E4, могу поуздано да процене поједине HRV мере у поређењу са референтним ЕКГ мерењима [8].

2.2 Бихевиорални експерименти за индукцију стреса

У истраживањима заснованим на физиолошким сигнаlima, различити типови стреса изазивају се стандардизованим лабораторијским протоколима. Физички стрес се уобичајено изазива вежбањем на покретној траци, при чему се оптерећење постепено повећава према унапред дефинисаном протоколу [9]. Когнитивни стрес се изазива задацима који захтевају одржану менталну пажњу и обраду конфликтних информација, попут Струп теста (енг. *Stroop test*), у коме испитаник именује боју штампе речи чије значење означава другу боју [10], или задатком серијског одузимања, у коме испитаник наглас и под временским притиском узастопно одузима фиксан број од задате вредности, задатак који чини основу Теста социјалног стреса у Триру (енг. *Trier Social Stress Test*, TSST) [11]. Емоционални стрес се најчешће изазива гледањем узнемирујућег видео садржаја, при чему избор материјала почива на истраживањима која потврђују да одређени филмски одломци поуздано изазивају циљано емоционално стање код већине испитаника [12].

Контролисани лабораторијски протоколи добијају предност у односу на мерења у реалним, свакодневним условима из неколико разлога: омогућавају понављивост услова између испитаника и између студија, тачно је познат тренутак почетка и тип стресора, чиме се олакшава поуздано означавање сигнала за потребе надгледањег учења, и смањује се утицај збуњујућих фактора присутних у неконтролисаном окружењу.

2.3 Обрада биосигнала

Пре екстракције обележја, сирови физиолошки сигнали пролазе кроз низ припремних корака. Филтрирање шума уклања компоненте сигнала ван физиолошки релевантног опсега, настале услед електричних сметњи, покрета сензора или других извора шума. Нормализација своди вредности сигнала на упоредиву скалу, чиме се умањују разлике у основном нивоу и осетљивости сензора између испитаника. Сегментација дели непрекидан сигнал на прозоре фиксне дужине, што омогућава примену истог поступка екстракције обележја и класификације над сваким прозором понаособ, уместо над целим снимком.

Уобичајен избор за филтрирање биосигнала јесте Батервортсов филтар (енг. *Butterworth filter*), препознатљив по равном фреквенцијском одзиву у пропусном опсегу. Да би се избегло изобличење облика сигнала услед фазног кашњења које

филтар уноси, филтрирање се често примењује у облику без фазног помераја (енг. *zero-phase filtering*), при чему се сигнал филтрира унапред и уназад, чиме се уведени фазни помак поништава. Анализа сигнала се потом спроводи у временском домену, посматрањем облика и статистичких својстава сигнала кроз време, или у фреквенцијском домену, посматрањем расподеле снаге сигнала по фреквенцијама, при чему су оба приступа комплементарна и у пракси се често комбинују.

2.4 Екстракција обележја из сигнала

У временском домену, обележја се рачунају директно из вредности сигнала унутар прозора и обухватају основне статистичке показатеље: средњу вредност, која описује ниво сигнала, стандардну девијацију, која описује варијабилност, асиметрију (енг. *skewness*), која описује облик расподеле вредности сигнала у односу на симетричну расподелу, и нагиб тренда, који описује смер и брзину промене сигнала унутар прозора.

У фреквенцијском домену, полазну тачку представља Фуријеова трансформација (енг. *Fourier transform*), која сигнал из временског преводи у фреквенцијски домен и открива које се фреквенцијске компоненте у њему налазе и колика је њихова снага. Резултат се уобичајено приказује као спектрална густина снаге (енг. *power spectral density*, PSD), односно расподела снаге сигнала по фреквенцији. За процену PSD из коначног и шумовитог узорка сигнала уобичајено се користи Велчова метода (енг. *Welch's method*), поступак који дели сигнал на преклапајуће сегменте, рачуна спектар сваког сегмента засебно и затим усредњава добијене спектре, чиме се смањује варијанса процене у односу на директну примену Фуријеове трансформације на цео сигнал. Анализа у фреквенцијском домену примењује се на физиолошке сигнале зато што је њихова основна динамика по природи периодична: откуцаји срца, циклуси дисања и понављајући обрасци покрета, те се њихова карактеристична фреквенција и снага на тој фреквенцији не могу директно прочитати из временског облика сигнала.

2.5 Машинско учење за класификацију

У сродним истраживањима класификације стреса из физиолошких сигнала користи се неколико устаљених алгоритама машинског учења. Логистичка регресија (енг. *logistic regression*) моделује вероватноћу припадности класи као линеарну комбинацију улазних обележја пропуштenu кроз логистичку функцију и представља једноставан, лако тумачив основни модел [13]. Стабла одлучивања деле простор обележја узастопним поделама по вредностима појединачних обележја, при чему свака подела бира обележје и праг који највише смањују нечистоћу класа у добијеним подскуповима; пошто су појединачна стабла склона прекомерном прилагођавању подацима, у пракси се чешће користе ансамбли стабала, попут случајне шуме

(енг. *Random Forest*), која комбинује предвиђања великог броја независно обучених стабала над насумичним подскуповима података и обележја [14], и градијентног појачавања (енг. *Gradient Boosting*), где се стабла обучавају узастопно, тако да свако наредно стабло исправља грешке претходних [15].

Скупови података за класификацију стреса често су неуравнотежени, јер је стање мировања обично заступљеније од појединачних стања стреса, што модел може усмерити ка фаворизовању веће класе. Уобичајен приступ ублажавању овог проблема представља пондерисање класа (енг. *class weighting*), при чему се погрешна класификација ређих класа током обуке кажњава сразмерно већим тежинским фактором [16]. Унакрсна валидација (енг. *cross-validation*) представља поступак процене перформанси модела дељењем података на више преклопа, при чему се модел у сваком преклопу обучава на једном подскупу, а тестира на преосталом. Код података прикупљених од више испитаника, чији су узорци међусобно корелисани, преклопи се уобичајено формирају груписањем по испитанику, тако да подаци истог испитаника никада нису истовремено у скупу за обуку и скупу за тестирање, чиме се спречава прецењивање перформанси услед цурења информација између скупова [17].

2.6 Метрике евалуације модела

Тачност (енг. *accuracy*) представља удео тачно класификованих узорака у укупном броју узорака, али је недовољна мера код неуравнотежених класа, пошто високу вредност може остварити и модел који увек предвиђа већинску класу. Прецизност (енг. *precision*) мери удео тачно позитивних предвиђања међу свим предвиђањима дате класе, док одзив (енг. *recall*) мери удео тачно препознатих примера међу свим стварним примерима те класе. F1 мера представља хармонијску средину прецизности и одзива по класи, док макро-усредњена F1 мера (енг. *macro-averaged F1 score*) представља просту средину F1 мера свих класа, без пондерисања према броју узорака по класи, услед чега свака класа добија једнак утицај на коначну оцену без обзира на своју заступљеност, што је чини погоднијом мером од тачности код неуравнотежених скупова података [18]. Матрица конфузије (енг. *confusion matrix*) приказује број предвиђања за сваку комбинацију стварне и предвиђене класе и омогућава детаљнију анализу грешака модела по класама, попут утврђивања са којом се другом класом одређена класа најчешће замењује, увид који агрегатне мере попут тачности или макро F1 мере саме по себи не пружају [18].

2.7 Преглед сродних истраживања

Скуп података коришћен у овом раду први пут је представљен у раду који описује протокол прикупљања и намену података за процену неуролошког стања применом носивих сензора [1]. Слична истраживања детекције стреса из носивих

сензора обухватају и WESAD (енг. *Wearable Stress and Affect Detection*) скуп података, који садржи физиолошке и покретне сигнале прикупљене током лабораторијског протокола са стањима мировања, стреса и забаве, праћене субјективним оценама афективног стања учесника [19]. Над истим PhysioNet скупом података коришћеним у овом раду спроведено је и истраживање које примењује декомпозицију тензора ради визуализације и препознавања стања стреса [20], што је релевантно за директно поређење резултата у дискусији у поглављу 4.

3.1 Архитектура система

Систем спроведен у оквиру рада организован је као низ узастопних корака обраде, од учитавања сирових сигнала до извоза резултата класификације. Сирови сигнали чувају се у WFDB (енг. *Waveform Database*) формату, стандардном формату за складиштење и размену физиолошких сигнала у истраживачке сврхе. Ток обраде обухвата следеће кораке:

1. учитавање сирових WFDB записа за сваког испитаника;
2. предобраду сигнала: филтрирање и нормализацију;
3. сегментацију непрекидног сигнала на прозоре фиксне дужине;
4. екстракцију обележја из сваког прозора, у временском и фреквенцијском домену;
5. контролу квалитета и селекцију обележја;
6. тренирање и подешавање хиперпараметара модела машинског учења;
7. евалуацију модела;
8. извоз резултата.

Сваки корак спроведен је као засебна, поновно употребљива функција, при чему излаз једног корака представља улаз наредног. Крајњи производ рада представља истраживачки ланац обраде, извршен над скупом података у целини.

3.2 Опис скупа података


Скуп података коришћен у раду доступан је на платформи PhysioNet, јавно доступном архиву физиолошких сигнала намењеном истраживањима у биомедицинском инжењерству, под називом *Non-EEG Dataset for Assessment of Neurological Status*. Назив упућује на то да процена неуролошког стања у скупу података почива искључиво на сигнаlima прикупљеним носивим сензором, без електроенцефалографског (EEG) снимања могуће активности. Скуп садржи снимке 20 здравих испитаника прикупљене сензором Empatica E4 постављеним на зглоб, током контролисаног лабораторијског протокола [1].

За сваког испитаника доступна су два одвојена записа. Запис AccTempEDA садржи сигнале акцелерометра, температуре коже и електродермалне активности, узорковане на 8Hz, праћене анотацијама које означавају границе фаза протокола. Запис SpO2HR садржи сигнале zasiћености крви кисеоником и срчане фреквенције, узор-


коване на 1Hz, без сопствених анотација; границе фаза за овај запис преузимају се из одговарајућег AccTempEDA записа истог испитаника, уз временско усклађивање према различитој учестаности узорковања два записа. Оба записа чувају се у WFDB формату, при чему је сваки запис представљен кроз три фајла: заглавље са метаподацима о сигналу (.hea), бинарни фајл узорака сигнала (.dat) и, где анотације постоје, фајл граница фаза (.atr).

Протокол се састоји од осам фаза, спроведених истим редоследом код свих испитаника: почетна фаза мировања (Relax, 5 минута), физички стрес изазван вежбањем на покретној траци (5,5 минута), поновна фаза мировања (5 минута), кратка фаза ишчекивања која најављује наредни емоционални стресор (40 секунди), когнитивни стрес изазван задатком серијског одузимања и Струп тестом (6 минута), фаза мировања (5 минута), емоционални стрес изазван гледањем узнемирујућег видео садржаја (6 минута) и завршна фаза мировања (5 минута).

Слика 1 приказује сирове сигнале записа AccTempEDA, а слика 2 сирове сигнале записа SpO2HR, за Испитаника 1, током целог протокола.



Слика 1: Сирови сигнали записа АссTempEDA (акцелерометар по осама, температура коже, електродермална активност) за Испитаника 1, током целог протокола; вертикалне линије означавају границе фаза.



Слика 2: Сирови сигнали записа SpO2HR (засићеност крви кисеоником и срчана фреквенција) за Испитаника 1, током целог протокола; вертикалне линије означавају границе фаза.


Скуп података погодан је за овај рад из неколико разлога. Јавно је доступан, чиме омогућава поновљивост анализе. Заснован је на контролисаном протоколу истог редоследа за све испитанике, што олакшава поуздано означавање сигнала. Покрива три различита типа стреса (физички, когнитивни и емоционални) и тако пружа финију гранулацију означавања него уобичајена бинарна ознака присуства стреса, коришћена у већини сродних скупова података. Заснован је, најзад, на реалном носивом сензору намењеном свакодневној употреби, а не на специјализованој лабораторијској опреми.

3.3 Предобрада сигнала

Пре екстракције обележја, оба записа сваког испитаника пролазе кроз поступак филтрирања и нормализације сигнала.

Филтрирање се спроводи Батервортим филтром 4. реда у облику без фазног помераја: сигнал се филтрира унапред, а затим уназад истим коефицијентима, чиме се уклања фазно кашњење које би филтар иначе унео и изобличио облик сигнала [21], [22]. Филтар се примењује селективно, по каналу, у зависности од односа фреквенцијског опсега од интереса за дати сигнал и Никвистове фреквенције (енг. *Nyquist frequency*) канала, односно половине учестаности узорковања, изнад које се дигитални сигнал не може поуздано представити без изобличења. Сигнали акцелерометра и сигнали срчане фреквенције и засићености крви кисеоником нису

филтрирани, јер опсег од интереса за ове сигнале досеже готово до саме Никвистове фреквенције њиховог канала и не оставља простор за граничну фреквенцију филтра која би уклонила шум без задирања у користан сигнал. Сигнали електродермалне активности и температуре коже филтрирани су ниско-пропусним филтром са граничном фреквенцијом 1,0 Hz, пошто њихов фреквенцијски опсег од интереса лежи знатно испод Никвистове фреквенције канала, остављајући простор за уклањање шума изнад те границе. Слика 3 приказује ефекат овог филтра на сигналу електродермалне активности за Испитаника 1.



Слика 3: Поређење сировог и филтрираног сигнала електродермалне активности за Испитаника 1, зумирано на прозор од 90 секунди (горе), и разлика сировог и филтрираног сигнала, односно садржај уклоњен филтрирањем (доле).

Нормализација се спроводи рачунањем z -скора (енг. z -score) сваког канала посебно, по испитанику, на основу средње вредности и стандардне девијације рачунатих над целим записом. Ове статистике рачунају се пре сегментације записа на прозоре, чиме се спречава да границе фаза протокола утичу на саме параметре нормализације: када би се средња вредност и стандардна девијација рачунале засебно по прозору или по фази, разлике између фаза биле би делимично апсорбоване у сам поступак нормализације, уместо да остану видљиве обележјима која се потом рачунају над нормализованим сигналом.

Сегментација дели сваку фазу протокола на прозоре дужине 60 секунди, са преклапањем од 50% између узастопних прозора, односно кораком од 30 секунди. Прозори никада не прелазе границу фазе: сваки прозор припада тачно једној фази, одређеној анотацијом протокола. Последица овог ограничења јесте да кратка фаза ишчекивања, у трајању од свега око 40 секунди, не може да испуни ниједан прозор

од 60 секунди и аутоматски отпада из анализе, без посебног изузимања по ознаци фазе.


3.4 Екстракција обележја

За сваки прозор рачуна се скуп обележја у временском и фреквенцијском домену, засебно за пет сигнала: магнитуду убрзања (изведена из три осе акцелерометра), електродермалну активност, температуру коже, срчану фреквенцију и засићеност крви кисеоником.

У временском домену, за свих пет сигнала рачунају се исти показатељи: средња вредност, стандардна девијација, асиметрија и нагиб тренда, добијен линеарном регресијом сигнала у односу на време унутар прозора.

У фреквенцијском домену примењује се Велчова метода [23], прилагођена карактеристикама сваког сигнала. За срчану фреквенцију спектар се процењује над целим прозором као једним сегментом, што при учестаности узорковања од 1Hz одговара 60 одбирака; при тако малом броју одбирака, додатно дељење прозора на подсегменте би непотребно погоршало већ грубу фреквенцијску резолуцију потребну за разлучивање нискофреквентне компоненте спектра. Из сличног разлога, спектар електродермалне активности такође се процењује над целим прозором, што при учестаности узорковања од 8Hz одговара 480 одбирака: уски фреквенцијски опсези од интереса, преузети из литературе, захтевају финију резолуцију од оне коју би дало усредњавање по краћим подсегментима. За акцелерометар се, насупрот томе, примењује усредњена Велчова метода над подсегментима од 16 секунди, чиме се смањује варијанса процене спектра и истиче доминантна фреквенција покрета током физичког стреса. За температуру коже рачуна се спектар истом усредњеном методом над подсегментима од 16 секунди, а за засићеност крви кисеоником над целим прозором, аналогно срчаној фреквенцији; за оба сигнала рачунају се само генерички дескриптори спектра.

Универзална обележја рачуната у фреквенцијском домену, заједничка за свих пет сигнала, обухватају укупну снагу спектра, доминантну фреквенцију и спектралну ентропију. Поред универзалних, за поједине сигнале рачунају се и обележја специфична за физиолошки процес који сигнал одражава. За срчану фреквенцију рачуна се однос LF/HF снаге. За електродермалну активност рачунају се тоничка снага и снага у ниском и високом симпатичком опсегу, према границама опсега утврђених у литератури за процену симпатичке функције из спектра електродермалне активности [24]. За акцелерометар рачунају се постурална и покретна снага, као и приближна учестаност корака, добијена као доминантна фреквенција у опсегу покрета, изражена током фазе физичког стреса. Слика 4 приказује спектрограм магнитуде убрзања за Испитаника 1, у фазама Relax и PhysicalStress.



Слика 4: Спектрограм магнитуде убрзања за Испитаника 1, у фазама Relax и PhysicalStress; уочљив је пораст снаге у опсегу покрета током физичког стреса.

Стандардне мере варијабилности срчане фреквенције, попут RMSSD и SDNN, не могу се израчунати над овим скупом података, пошто он садржи само унапред усредњену срчану фреквенцију у откуцајима у минути на 1Hz, без сировог PPG таласног облика из ког би се детектовао сваки појединачни откуцај и израчунао низ RR интервала. Уместо стандардних HRV мера рачунају се показатељи сукцесивних разлика суседних вредности срчане фреквенције у прозору: корен средње квадратне вредности, стандардна девијација, минимум, максимум, медијана и нагиб тренда низа разлика.

Над свим израчунатим обележјима спроводи се контрола квалитета. Прво се проверава присуство NaN и бесконачних (Inf) вредности, насталих, на пример, дељењем нулом при рачунању односа снага. Затим се проверавају границе изведене из саме дефиниције обележја: обележја снаге, ентропије и односа морају бити ненегативна, а доминантна фреквенција мора остати унутар опсега од нуле до Никвистове фреквенције канала ком припада. Вредности које нарушавају ове границе, обично услед нумеричког шума на граничном случају (на пример, ентропија незнатно испод нуле код спектра концентрисаног у једном одбирку), ограничавају се на најближу дозвољену вредност, уместо да се цео прозор одбаци; на тај начин се чувају вредности осталих, исправних обележја тог прозора.

3.5 Селекција обележја

Полазни скуп обележја, добијен спајањем свих сигнала и обе групе обележја (временски и фреквенцијски домен), броји укупно 51 обележје. Селекција обележја спроводи се методом пермутационе важности (енг. *permutation importance*) на тренираном Random Forest моделу: за свако обележје понаособ, вредности тог обележја се насумично премештају међу узорцима, а затим се мери пад перформанси модела у односу на перформансе са неизмењеним обележјем. Обележја чији је губитак перформанси при пермутацији низак или негативан сматрају се мало информативним за модел.

Пермутациона важност претпостављена је у односу на уграђену важност обележја (енг. *impurity-based importance*), коју Random Forest модел иначе рачуна током тренирања на основу смањења нечистоће коју свако обележје доноси при дељењу чворова стабла [14]. Уграђена важност систематски фаворизује обележја са великим бројем могућих тачака поделе, односно непрекидна обележја са великим бројем различитих вредности, чак и када таква обележја нису стварно информативнија за класификацију [25]. Пермутациона важност ову пристрасност избегава, јер мери директно промену перформанси модела изазвану пермутацијом вредности обележја, независно од унутрашње структуре стабла.

Применом пермутационе важности уклоњено је 9 од укупно 51 обележја, чија је измерена важност била мања или једнака нули.

Посебан случај представљала је група обележја сукцесивних разлика срчане фреквенције, уведена у претходном потпоглављу: свако од њих појединачно рангирано је ниско пермутационом важношћу. Аблациона анализа (енг. *ablation study*), односно уклањање целе групе обележја и поновно мерење перформанси модела, показала је, међутим, пад макро-усредњене F1 мере при уклањању читаве те групе обележја одједном. Из овога следи да корелисана обележја треба оцењивати групном аблацијом, јер њихов појединачни пермутациони ранг не мора одражавати стварни заједнички допринос групе класификацији.

Конечан скуп обележја коришћен за тренирање модела броји 42 од 51 обележја.

3.6 Модели машинског учења

За класификацију прозора у једну од четири класе користи се исти редослед корака за сва три модела: стандардизација обележја помоћу StandardScaler, праћена класификатором. Стандардизација своди свако обележје на средњу вредност 0 и стандардну девијацију 1, чиме се отклањају разлике у скали између обележја различите физичке природе, на пример снаге спектра наспрам нагиба тренда; ово је посебно битно за логистичку регресију, чији коефицијенти директно зависе од скале улазних променљивих.

Због неуравнотежености класа у скупу података, где фаза Relax чини приближно 54% свих прозора, сваки класификатор користи пондерисање класа постављањем параметра `class_weight='balanced'`, чиме се погрешна класификација ређих класа током тренирања казни сразмерно већом тежином.

Упоређена су три модела: логистичка регресија, Random Forest и Gradient Boosting, имплементиран кроз HistGradientBoostingClassifier. Логистичка регресија служи као једноставан, лако тумачив основни модел за поређење. Random Forest и Gradient Boosting представљају два комплементарна приступа ансамблима стабала одлучивања, са различитим механизмом комбиновања појединачних стабала,

чиме се омогућава поређење да ли сложенији, нелинеарни модели доносе предност у односу на једноставнији линеарни модел на овом скупу обележја. Алгоритми коришћени за класификацију већ су представљени у поглављу 2.

3.7 Валидација и подешавање хиперпараметара

Ваљаност модела процењује се методом `StratifiedGroupKFold`, са 5 преклопа, при чему се груписање спроводи по испитанику: сви прозори истог испитаника припадају искључиво једном преклопу, било тренинг било тест скупу. Груписање по испитанику обавезно је због начина сегментације описаног у претходном потпоглављу: суседни прозори се преклапају 50%, па би без груписања велики део садржаја једног прозора могао да се понови у суседном прозору истог испитаника који заврши у супротном скупу, чиме би се прецениле стварне перформансе модела услед цурења информација између тренинг и тест скупа. Поред груписања, преклопи су стратификовани према класи ознаке, тако да се однос заступљености четири класе (`Relax`, `Physical`, `Cognitive`, `Emotional`) одржава приближно једнак у сваком преклопу.

Хиперпараметар представља параметар модела чија се вредност задаје пре тренирања. Подешавање хиперпараметара спроводи се методом `GridSearchCV`: за сваку комбинацију вредности из унапред задате мреже параметара, модел се тренира и оцењује унакрсном валидацијом описаном изнад, а бира се комбинација са најбољом просечном макро-усредњеном F1 мером.

За логистичку регресију претражује се параметар регуларизације `C`, из скупа вредности 0,01; 0,1; 1; 10 и 100. За `Random Forest` претражују се број стабала `n_estimators` из скупа 200, 300 и 500, максимална дубина стабла `max_depth` из скупа без ограничења, 10 и 20, и минималан број узорака у листу `min_samples_leaf` из скупа 1, 2 и 5. За `Gradient Boosting` претражују се максималан број итерација `max_iter` из скупа 100, 200 и 300, максимална дубина стабла `max_depth` из скупа без ограничења, 5 и 10, и стопа учења `learning_rate` из скупа 0,05; 0,1 и 0,2.

3.8 Извоз резултата

Резултати добијени у сваком кораку ланца обраде извозе се и чувају засебно, ради даље анализе и поновљивости резултата.

Обележја израчуната у фреквенцијском и временском домену извозе се у одвојене CSV фајлове (`frequency_features.csv` и `statistical_features.csv`), који се потом спајају у јединствену табелу обележја (`combined_features.csv`) коришћену за тренирање и евалуацију модела. Резултати евалуације модела такође се чувају као засебан излаз поступка: за сваки модел чувају се извештај о класификацији (`classification_report`), са прецизношћу, одзивом и F1 мером по класи, и матрица конфузије. Поред обележја и извештаја, чува се и сам трениран модел, што

омогућава да се коначни модел поново употреби без поновног извршавања целог поступка тренирања. Овакав приступ извозу међурезултата и коначних резултата омогућава да се анализа резултата у наредном поглављу спроводи независно од поновног извршавања целог ланца обраде.


4.1 Перформансе модела

Три модела машинског учења, описана у поглављу 3, подешена су методом GridSearchCV уз StratifiedGroupKFold унакрсну валидацију са 5 преклопа груписаних по испитанику. Поређење се врши по макро-усредњеној F1 мери, усредњеној преко свих преклопа. Табела 1 приказује макро F1 меру и најбоље пронађене хиперпараметре за свака три модела.

Табела 1: Поређење макро F1 мере и најбољих хиперпараметара за три подешена модела.

Модел	Макро F1 мера	Најбољи хиперпараметри
Логистичка регресија	0,744	C = 0,1
Random Forest	0,770	n_estimators = 500, max_depth = 20, min_samples_leaf = 1
Gradient Boosting	0,758	max_iter = 100, без ограничења дубине стабла, learning_rate = 0,2


Слика 5 приказује исто поређење графички, са граничним вредностима стандардне девијације по преклопима унакрсне валидације. Random Forest остварује највишу макро F1 меру, док Gradient Boosting и логистичка регресија остају нешто испод, у оквиру преклапајућег опсега стандардне девијације.



Слика 5: Поређење макро F1 мере три подешена модела, са граничним вредностима стандардне девијације по преклопима унакрсне валидације.

4.2 Детаљни резултати најбољег модела

Random Forest, као модел са највишом макро F1 мером, детаљније се анализира у овом потпоглављу. Слика 6 приказује матрице конфузије сва три подешена модела, изражене у процентима у односу на стварну класу; средњи панел приказује Random Forest.



Слика 6: Матрице конфузије три подешена модела, у процентима по стварној класи (Logistic Regression, Random Forest, Gradient Boosting).

Матрица конфузије за Random Forest показује да се класе Relax и PhysicalStress препознају са високом тачношћу, док се класа EmotionalStress најчешће меша са класом Relax. Табела 2 приказује пун извештај о класификацији (classification_report) за Random Forest, са прецизношћу, одзивом и F1 мером по класи.


Табела 2: Извештај о класификацији за Random Forest: прецизност, одзив и F1 мера по класи, укупна тачност, макро-усредњене и пондерисано-усредњене вредности.

Класа	Прецизност	Одзив	F1 мера	Број узорака
Relax	0,843	0,824	0,833	709
PhysicalStress	0,951	0,967	0,959	180
CognitiveStress	0,739	0,746	0,743	201
EmotionalStress	0,534	0,561	0,547	223
тачност			0,787	1313
макро-усредњено	0,767	0,774	0,770	1313
пондерисано-усредњено	0,789	0,787	0,788	1313

PhysicalStress остварује најбољу F1 меру међу четири класе, док EmotionalStress остварује најнижу. Укупна тачност модела износи 0,787, а макро-усредњена F1 мера 0,770.

4.3 Анализа важности обележја

Пермутациона важност, метода описана у поглављу 3, примењује се и у овом потпоглављу ради анализе доприноса појединачних обележја. Слика 7 приказује 15 обележја са највишом пермутационом важношћу, рачунатом на неподешеном Random Forest моделу (`n_estimators = 300`, остали параметри подразумевани), фитованом на пун скуп од 42 обележја, независно од коначног подешеног модела представљеног у претходна два потпоглавља.



Слика 7: Топ 15 обележја по пермутационој важности (пад макро F1 мере при пермутацији), рачунато на неподешеном Random Forest моделу.

Најважније обележје је средња вредност електродермалне активности (`eda_mean`, 0,049), непосредно праћена средњом вредношћу срчане фреквенције (`hr_mean`, 0,043). Треће по важности обележје је средња вредност температуре коже (`temp_mean`, 0,030), што представља неочекиван налаз, пошто се температура коже пре спроведене анализе није сматрала снажним показатељем стреса. Средња вредност засићености крви кисеоником (`spo2_mean`, 0,0076) и снага покрета из акцелерометра (`acc_movement_power`, 0,0034) заузимају наредна места, знатно испод прва два обележја по величини доприноса.

Ради провере доприноса обележја температуре коже и засићености крви кисеоником, спроведена је аблациона анализа: сва обележја изведена из ова два сигнала уклоњена су из скупа обележја, чиме је број обележја смањен са 42 на 30. Табела 3 приказује пад макро F1 мере за свака три модела.

Табела 3: Пад макро F1 мере при уклањању свих обележја изведених из температуре коже и засићености крви кисеоником (аблациона анализа).

Модел	Макро F1 (42 обележја)	Макро F1 (30 обележја)	Δ
Логистичка регресија	0,744	0,704	-0,040
Random Forest	0,770	0,744	-0,026
Gradient Boosting	0,758	0,731	-0,027

Пад перформанси при уклањању ова два сигнала није занемарљив, чиме се претпоставка о њиховој потпуној неинформативности показује нетачном. За Random Forest, пад по класи износи: Relax F1 0,821 (Δ -0,012), PhysicalStress F1 0,925 (Δ -0,034), CognitiveStress F1 0,721 (Δ -0,022) и EmotionalStress F1 0,510 (Δ -0,037), уз укупну тачност 0,765 и макро-усредњену F1 меру 0,744. Најизраженији пад запажа се код класа PhysicalStress и EmotionalStress. Разлог оволиког пада перформансе, укључујући и његову везу са редоследом фаза протокола, разматра се у наредном потпоглављу; макро F1 мера од 0,744, добијена без обележја температуре и засићености крви кисеоником, представља поузданију процену стварних перформанси модела од пуног резултата 0,770, чији део доприноса потиче од ефекта забуне описаног у наставку.

4.4 Дискусија резултата

Резултат овог рада, макро F1 мера 0,770 за Random Forest над четири класе, упоредив је са резултатима сродних истраживања наведених у поглављу 2. Birjandtalab и сарадници, аутори скупа података коришћеног у овом раду, показују да се применом ненадгледаног Gaussian Mixture Model кластеровања четири стања неуролошког статуса могу успешно раздвојити [1]; овај резултат није непосредно упоредив са резултатима овог рада, пошто се заснива на ненадгледаном кластеровању, без надгледане поделе на тренинг и тест скуп по испитанику. WESAD скуп података, у истраживању Schmidt и сарадника, садржи три афективна стања (baseline, stress, amusement) снимљена, поред осталог, носивим сензором на зглобу; коришћењем искључиво физиолошких обележја са зглоба (BVP, EDA, температура) и Random Forest модела, уз унакрсну валидацију остављањем једног испитаника ван скупа, остварена је F1 мера 0,663 и тачност 0,762 [19]. Овај резултат представља најближу упоредиву тачку са резултатом овог рада, пошто користи исти тип носивог сензора и надгледану класификацију по испитанику; резултат овог рада (макро F1 мера 0,770) виши је упркос томе што разликује четири класе уместо три. Pham и сарадници, применом декомпозиције тензора над истим PhysioNet скупом података коришћених у овом раду, извештавају о раздвајању четири групе неуролошког статуса тачношћу до 100% [20]; детаљи протокола валидације, укључујући и то да

ли је примењено груписање по испитанику, нису познати из доступних извора, због чега овај резултат треба узети са резервом при поређењу.

Физички стрес представља најлакше препознатљиву класу, са F1 мером 0,959. Овакав резултат у складу је са налазом да су снага покрета из акцелерометра и средња вредност срчане фреквенције међу најважнијим обележјима по пермутационој важности: физичко вежбање на покретној траци изазива изражену и специфичну промену и у покрету и у срчаној фреквенцији, за разлику од когнитивног и емоционалног стреса, код којих су промене суптилније.

Емоционални стрес представља најтеже препознатљиву класу, са F1 мером 0,547. Разлог томе делом лежи у редоследу фаза протокола: емоционални стрес спроводи се као последња стресна фаза, након физичког и когнитивног стреса. Реактивност електродермалне активности и срчане фреквенције на нови стресор слаби услед понављањем излагања претходним фазама стреса током исте сесије, феномен познат као хабитуација, чиме се смањује разлика између сигнала у фази EmotionalStress и сигнала у преосталим фазама.

Средња вредност температуре коже (temp_mean) заузима треће место по пермутационој важности, упркос томе што пре спроведене анализе није очекивана као снажан показатељ стреса. Корелација овог обележја са редним бројем прозора у оквиру сесије (window_index) износи 0,755, што указује на то да температура коже монотонно расте током сесије, независно од тога која фаза протокола тренутно траје. Пошто сви испитаници пролазе кроз исти, фиксни редослед фаза, ова временска зависност делује као посредни показатељ протеклог времена у сесији, а не искључиво као физиолошки одговор на тип стреса.

Засићеност крви кисеоником и температура коже разликују се по физиолошком основу за очекивани допринос класификацији. Засићеност крви кисеоником код здравих испитаника строго је хомеостатски регулисана и нема физиолошки разлог да реагује на психолошки стрес, те низак допринос овог обележја одговара очекивању. Температура коже, насупрот томе, представља физиолошки ваљан показатељ стреса, посредован периферном вазоконстрикцијом. Проблем уочен у овом раду специфичан је за примењени протокол, односно за фиксни редослед фаза који уводи ефекат забуне описан изнад, а не за физиолошку информативност температуре коже као сигнала.

Пад F1 мере код класа PhysicalStress и EmotionalStress при аблацији обележја температуре коже и засићености крви кисеоником није у потпуности објашњив ефектом забуне код temp_mean. Могуће је да део пада потиче од стварног, самосталног физиолошког доприноса ова два сигнала код ове две класе, на пример пролазног пада засићености крви кисеоником и промене температуре коже под стварним физич-

ким напором. Раздвајање стварног физиолошког доприноса од ефекта позиције у сесији захтевало би изоловано тестирање сваког сигнала понаособ, што превазилази оквире овог рада и наводи се као правац даљег рада у поглављу 5.

5.1 Резиме

Рад је представио истраживачки ланац обраде физиолошких сигнала са носивог сензора на зглобу, од учитавања сирових WFDB записа до класификације типа стреса у једну од четири класе: Relax, Physical, Cognitive и Emotional. Ланац обраде обухвата филтрирање и нормализацију сигнала, сегментацију на прозоре фиксне дужине, екстракцију обележја у временском и фреквенцијском домену, селекцију обележја методом пермутационе важности, те тренирање и подешавање три класична модела машинског учења.

Резултати показују да је могуће разликовати тип стреса из сигнала измерених носивим сензором на зглобу, са тачношћу која се креће од умерене до добре, у зависности од типа стреса. Физички стрес препознаје се поуздано, услед изражене и специфичне промене у покрету и срчаној фреквенцији. Когнитивни стрес препознаје се са нешто нижом поузданошћу, док емоционални стрес представља најслабију тачку система: хабитуација услед положаја ове фазе на крају протокола умањује разлику између сигнала емоционалног стреса и стања мировања. Поред саме класификације, анализа важности обележја открила је да температура коже уноси ефекат забуне услед фиксног редоследа фаза протокола, налаз који мења тумачење доприноса овог сигнала класификацији и представља посебан методолошки резултат рада.

5.2 Ограничења система

Систем спроведен у раду носи неколико ограничења која произлазе из природе расположивог скупа података и примењене методологије и која се у оквиру овог рада не могу отклонити:

- Скуп података обухвата свега 20 испитаника, услед чега су резултати појединачних преклопа унакрсне валидације статистички шумовити и осетљиви на састав преклопа.
- Детекција је ограничена на фиксни, контролисани лабораторијски протокол, па добијени резултати не морају да се пренесу на препознавање стреса у свакодневним, неконтролисаним условима.
- Показатељи сукцесивних разлика срчане фреквенције, уведени у поглављу 3 као посредни показатељи варијабилности срчане фреквенције, не представљају праве

- стандардне HRV мере попут RMSSD или SDNN, пошто скуп података не садржи сирови PPG таласни облик потребан за детекцију појединачних откуцаја.
- Сигнал акцелерометра доступан је на учестаности узорковања од 8Hz, знатно нижој од изворне резолуције сензора Empatica E4 од 32Hz, чиме је ограничен опсег анализе покрета.
 - Подешавање хиперпараметара методом GridSearchCV спроведено је на истој подели података која се користи за финалну евалуацију модела, без потпуно угнежђене унакрсне валидације; овакво поједностављење представља ограничење услед премалог броја испитаника за одвајање додатног, унутрашњег нивоа преклопа.
 - Емоционални стрес препознаје се само до одређене мере, услед хабитуације описане у поглављу 4; кратка фаза ишчекивања која претходи емоционалном стресору, у трајању од свега око 40 секунди, мора бити у потпуности искључена из анализе, пошто не попуњава ниједан прозор од 60 секунди.

5.3 Изазови и прилагођавања током рада

Одлука да се коначни, извештени модел заснива на скупу од 30 обележја, без обележја изведених из температуре коже и засићености крви кисеоником, донета је накнадно, током анализе важности обележја описане у поглављу 4. Засићеност крви кисеоником искључена је зато што код здравих испитаника нема физиолошки основ за реаговање на психолошки стрес, пошто је овај сигнал строго хомеостатски регулисан; низак допринос овог обележја класификацији у складу је са овим очекивањем. Температура коже искључена је из другог разлога: обележје `temp_mean` показало се високо ранжираним по пермутационој важности, али је накнадна анализа открила високу корелацију овог обележја са редним бројем прозора у сесији. Овакав образац указује на ефекат забуне узрокован фиксним редоследом фаза протокола: температура коже монотонно расте током сесије, независно од тога која фаза тренутно траје. Модел без ова два сигнала остварује макро F1 меру 0,744, нешто нижу од 0,770 остварене са пуним скупом обележја, али представља поузданију процену стварних перформанси, ослобођену доприноса откривеног ефекта забуне.

Прилагођавање Велчове методе процене спектралне густине снаге различитим учестаностима узорковања по каналу представљало је технички изазов током рада. Пет коришћених сигнала узорковано је на различитим учестаностима и носи различите циљане фреквенцијске опсеге. Дужина Велчовог сегмента морала је бити одабрана појединачно за сваки сигнал, у складу са учестаношћу узорковања и фреквенцијским опсегом од интереса, описаним у поглављу 3.

Груписање по испитанику у унакрсној валидацији уведено је током рада као решење за ризик цурења података између тренинг и тест скупа. Пошто се суседни прозори преклапају 50%, поступак валидације без груписања по испитанику омогу-

ћио би да садржај једног прозора буде готово идентичан садржају суседног прозора истог испитаника који заврши у супротном скупу, тренинг или тест, чиме би се измерене перформансе модела вештачки увећале. Проблем је решен применом `StratifiedGroupKFold` уместо обичне стратификоване унакрсне валидације, чиме је обезбеђено да сви прозори истог испитаника припадају искључиво једном преклопу.

Избор класичних модела машинског учења над ручно осмишљеним обележјима, уместо дубоког учења примењеног непосредно над сировим сигналом, донет је из два разлога. Скуп података од 20 испитаника недовољан је за поуздано тренирање дубоких неуронских мрежа, којима је обично потребан знатно већи број независних узорака да би се избегло прекомерно прилагођавање. Класични модели над ручно осмишљеним обележјима задржавају интерпретабилност на нивоу појединачног обележја, што је методом пермутационе важности омогућило откривање ефекта забуне код температуре коже, налаз који би у моделу заснованом на дубоком учењу над сировим сигналом остао прикривен унутар научених представа сигнала.

5.4 Даља потенцијална унапређења

Резултати и ограничења уочена у раду отварају неколико праваца даљег рада:

- Прикупљање или коришћење већег и разноврснијег скупа података, са већим бројем испитаника и, по могућству, променљивим редоследом фаза протокола између испитаника, чиме би се омогућило раздвајање ефекта забуне температуре коже, описаног у поглављу 4, од стварног физиолошког доприноса овог сигнала.
- Коришћење сировог PPG таласног облика, уместо унапред усредњене срчане фреквенције, за рачунање стандардних HRV мера попут RMSSD и SDNN, чиме би посредни показатељи коришћени у овом раду били замењени признатим мерама варијабилности срчане фреквенције.
- Независна анализа која би раздвојила стваран физиолошки допринос температуре коже и засићености крви кисеоником од утицаја положаја прозора у сесији. У поглављу 4 показано је да пад F1 мере код класа `PhysicalStress` и `EmotionalStress` при аблацији обележја ова два сигнала није у потпуности објашњив ефектом забуне код `temp_mean`, и да преостали део пада вероватно потиче од стварног, самосталног физиолошког доприноса ова два сигнала, на пример пролазног пада засићености крви кисеоником или промене температуре коже под стварним физичким напором. Раздвајање овог доприноса од утицаја положаја у сесији захтевало би изоловано тестирање сваког сигнала понаособ, на пример поређењем испитаника изложених различитом редоследу фаза протокола или контролисаним експериментом у коме се исти стресори примењују у више сесија

са измењеним редоследом код истих испитаника, чиме би се утицај протеклог времена у сесији статистички одвојио од утицаја конкретне фазе стреса.

- Тестирање модела на подацима прикупљеним ван лабораторијских услова, ради процене еколошке валидности резултата, односно способности модела да препозна тип стреса у свакодневним, неконтролисаним условима коришћења носивог сензора.

Списак слика

- Слика 1 Сирови сигнали записа AccTempEDA (акцелерометар по осама, температура коже, електродермална активност) за Испитаника 1, током целог протокола; вертикалне линије означавају границе фаза. 11
- Слика 2 Сирови сигнали записа SpO2HR (засићеност крви кисеоником и срчана фреквенција) за Испитаника 1, током целог протокола; вертикалне линије означавају границе фаза. 12
- Слика 3 Поређење сировог и филтрираног сигнала електродермалне активности за Испитаника 1, зумирано на прозор од 90 секунди (горе), и разлика сировог и филтрираног сигнала, односно садржај уклоњен филтрирањем (доле). 13
- Слика 4 Спектрограм магнитуде убрзања за Испитаника 1, у фазама Relax и PhysicalStress; уочљив је пораст снаге у опсегу покрета током физичког стреса. 15
- Слика 5 Поређење макро F1 мере три подешена модела, са граничним вредностима стандардне девијације по преклопима унакрсне валидације. 20
- Слика 6 Матрице конфузије три подешена модела, у процентима по стварној класи (Logistic Regression, Random Forest, Gradient Boosting). 20
- Слика 7 Топ 15 обележја по пермутационој важности (пад макро F1 мере при пермутацији), рачунато на неподешеном Random Forest моделу. 22

Списак табела

Табела 1	Поређење макро F1 мере и најбољих хиперпараметара за три подешена модела.	19
Табела 2	Извештај о класификацији за Random Forest: прецизност, одзив и F1 мера по класи, укупна тачност, макро-усредњене и пондерисано-усредњене вредности.	21
Табела 3	Пад макро F1 мере при уклањању свих обележја изведених из температуре коже и засићености крви кисеоником (аблациона анализа).	23

Списак коришћених скраћеница

Скраћеница	Опис
EDA	Electrodermal Activity (електродермална активност)
EEG	Electroencephalography (електроенцефалографија)
HRV	Heart Rate Variability (варијабилност срчане фреквенције)
LF/HF	Low Frequency/High Frequency ratio (однос ниско- и високофреквентне компоненте спектра варијабилности срчане фреквенције)
PPG	Photoplethysmography (фотоплетизмографија)
PSD	Power Spectral Density (спектрална густина снаге)
RMSSD	Root Mean Square of Successive Differences (корен средње квадратне вредности сукцесивних разлика RR интервала)
SDNN	Standard Deviation of NN Intervals (стандардна девијација трајања интервала између откуцаја срца)
SpO ₂	Blood Oxygen Saturation (засићеност крви кисеоником)
TSST	Trier Social Stress Test (Тест социјалног стреса у Триру)
WESAD	Wearable Stress and Affect Detection (скуп података за детекцију стреса и афективног стања помоћу носивих сензора)
WFDB	Waveform Database (формат за складиштење и размену физиолошких сигнала)

Списак коришћених појмова

Појам	Објашњење
Аблациона анализа	Поступак уклањања дела улаза (нпр. групе обележја) и поновног мерења перформанси модела, ради процене стварног доприноса уклоњеног дела.
Ефекат забуне	Појава да обележје изгледа информативно за класификацију зато што је повезано са неким скривеним, паралелним фактором (нпр. протеклом времена у сесији), а не са физиолошким одговором који се заправо мери.
Велчова метода	Поступак процене спектралне густине снаге сигнала дељењем на преклапајуће сегменте, рачунањем спектра сваког сегмента и усредњавањем добијених спектра.
Батервортов филтар	Тип дигиталног филтра препознатљив по равном фреквенцијском одзиву у пропусном опсегу, коришћен за уклањање шума из сигнала.
Никвистова фреквенција	Половина учестаности узорковања сигнала; највиша фреквенција коју је могуће поуздано представити у дигиталном сигналу без изобличења.
Пермутациона важност	Метода процене важности обележја за модел машинског учења, заснована на мерењу пада перформанси модела када се вредности тог обележја насумично премешају међу узорцима.
Хабитуација	Слабљење физиолошке реакције организма на стресор услед понављањем или продуженог излагања сличним стресорима.

Биографија

Овде написати своју кратку биографију.

Литература

- [1] J. Birjandtalab, D. Cogan, M. B. Pouyan, and M. Nourani, “A Non-EEG Biosignals Dataset for Assessment and Visualization of Neurological Status,” in *2016 IEEE International Workshop on Signal Processing Systems (SiPS)*, Dallas, TX, USA, 2016, pp. 110–114. doi: [10.1109/SiPS.2016.27](https://doi.org/10.1109/SiPS.2016.27).
- [2] J. Allen, “Photoplethysmography and its application in clinical physiological measurement,” *Physiological Measurement*, vol. 28, no. 3, pp. R1–R39, 2007, doi: [10.1088/0967-3334/28/3/R01](https://doi.org/10.1088/0967-3334/28/3/R01).
- [3] A. Jubran, “Pulse oximetry,” *Critical Care*, vol. 19, no. 1, p. 272, 2015, doi: [10.1186/s13054-015-0984-8](https://doi.org/10.1186/s13054-015-0984-8).
- [4] W. Boucsein, *Electrodermal Activity*, 2nd ed. Boston, MA: Springer, 2012. doi: [10.1007/978-1-4614-1126-0](https://doi.org/10.1007/978-1-4614-1126-0).
- [5] K. A. Herborn *et al.*, “Skin temperature reveals the intensity of acute stress,” *Physiology & Behavior*, vol. 152, pp. 225–230, 2015, doi: [10.1016/j.physbeh.2015.09.032](https://doi.org/10.1016/j.physbeh.2015.09.032).
- [6] C.-C. Yang and Y.-L. Hsu, “A Review of Accelerometry-Based Wearable Motion Detectors for Physical Activity Monitoring,” *Sensors*, vol. 10, no. 8, pp. 7772–7788, 2010, doi: [10.3390/s100807772](https://doi.org/10.3390/s100807772).
- [7] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, “Heart rate variability: Standards of measurement, physiological interpretation, and clinical use,” *Circulation*, vol. 93, no. 5, pp. 1043–1065, 1996, doi: [10.1161/01.CIR.93.5.1043](https://doi.org/10.1161/01.CIR.93.5.1043).
- [8] A. A. T. Schuurmans *et al.*, “Validity of the Empatica E4 Wristband to Measure Heart Rate Variability (HRV) Parameters: A Comparison to Electrocardiography (ECG),” *Journal of Medical Systems*, vol. 44, no. 11, p. 190, 2020, doi: [10.1007/s10916-020-01648-w](https://doi.org/10.1007/s10916-020-01648-w).
- [9] R. A. Bruce, J. R. Blackmon, J. W. Jones, and G. Strait, “Exercising Testing in Adult Normal Subjects and Cardiac Patients,” *Pediatrics*, vol. 32, no. 4, pp. 742–756, 1963, doi: [10.1542/peds.32.4.742](https://doi.org/10.1542/peds.32.4.742).
- [10] J. R. Stroop, “Studies of interference in serial verbal reactions,” *Journal of Experimental Psychology*, vol. 18, no. 6, pp. 643–662, 1935, doi: [10.1037/h0054651](https://doi.org/10.1037/h0054651).

-
- [11] C. Kirschbaum, K.-M. Pirke, and D. H. Hellhammer, "The 'Trier Social Stress Test' – A Tool for Investigating Psychobiological Stress Responses in a Laboratory Setting," *Neuropsychobiology*, vol. 28, no. 1–2, pp. 76–81, 1993, doi: [10.1159/000119004](https://doi.org/10.1159/000119004).
- [12] J. J. Gross and R. W. Levenson, "Emotion elicitation using films," *Cognition & Emotion*, vol. 9, no. 1, pp. 87–108, 1995, doi: [10.1080/02699939508408966](https://doi.org/10.1080/02699939508408966).
- [13] D. W. Hosmer, S. Lemeshow, and R. X. Sturdivant, *Applied Logistic Regression*, 3rd ed. John Wiley & Sons, 2013. doi: [10.1002/9781118548387](https://doi.org/10.1002/9781118548387).
- [14] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [15] J. H. Friedman, "Greedy Function Approximation: A Gradient Boosting Machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001, doi: [10.1214/aos/1013203451](https://doi.org/10.1214/aos/1013203451).
- [16] H. He and E. A. Garcia, "Learning from Imbalanced Data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009, doi: [10.1109/TKDE.2008.239](https://doi.org/10.1109/TKDE.2008.239).
- [17] S. Saeb, L. Lonini, A. Jayaraman, D. C. Mohr, and K. P. Kording, "The need to approximate the use-case in clinical machine learning," *GigaScience*, vol. 6, no. 5, p. gix019, 2017, doi: [10.1093/gigascience/gix019](https://doi.org/10.1093/gigascience/gix019).
- [18] M. Sokolova and G. Lapalme, "A systematic analysis of performance measures for classification tasks," *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009, doi: [10.1016/j.ipm.2009.03.002](https://doi.org/10.1016/j.ipm.2009.03.002).
- [19] P. Schmidt, A. Reiss, R. Duerichen, C. Marberger, and K. V. Laerhoven, "Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection," in *Proceedings of the 20th ACM International Conference on Multimodal Interaction (ICMI '18)*, 2018, pp. 400–408. doi: [10.1145/3242969.3242985](https://doi.org/10.1145/3242969.3242985).
- [20] T. T. T. Pham, H. R. Deniz, and T. D. Pham, "Tensor Decomposition of Non-EEG Physiological Signals for Visualization and Recognition of Human Stress," in *Proceedings of the 2019 11th International Conference on Bioinformatics and Biomedical Technology (ICBBT '19)*, 2019, pp. 132–136. doi: [10.1145/3340074.3340096](https://doi.org/10.1145/3340074.3340096).
- [21] S. Butterworth, "On the Theory of Filter Amplifiers," *Experimental Wireless and the Wireless Engineer*, vol. 7, pp. 536–541, 1930, [Online]. Доступно на <https://people.eecs.ku.edu/~demarest/212/Buttorworth%20Orig.%20Paper.pdf>
- [22] F. Gustafsson, "Determining the Initial States in Forward-Backward Filtering," *IEEE Transactions on Signal Processing*, vol. 44, no. 4, pp. 988–992, 1996, doi: [10.1109/78.492552](https://doi.org/10.1109/78.492552).

-
- [23] P. D. Welch, “The Use of Fast Fourier Transform for the Estimation of Power Spectra: A Method Based on Time Averaging Over Short, Modified Periodograms,” *IEEE Transactions on Audio and Electroacoustics*, vol. 15, no. 2, pp. 70–73, 1967, doi: [10.1109/TAU.1967.1161901](https://doi.org/10.1109/TAU.1967.1161901).
- [24] H. F. Posada-Quintero, J. P. Florian, Á. D. Orjuela-Cañón, T. Aljama-Corrales, S. Charleston-Villalobos, and K. H. Chon, “Power Spectral Density Analysis of Electrodermal Activity for Sympathetic Function Assessment,” *Annals of Biomedical Engineering*, vol. 44, no. 10, pp. 3124–3135, 2016, doi: [10.1007/s10439-016-1606-6](https://doi.org/10.1007/s10439-016-1606-6).
- [25] C. Strobl, A.-L. Boulesteix, A. Zeileis, and T. Hothorn, “Bias in random forest variable importance measures: Illustrations, sources and a solution,” *BMC Bioinformatics*, vol. 8, p. 25, 2007, doi: [10.1186/1471-2105-8-25](https://doi.org/10.1186/1471-2105-8-25).